

Семантическое разнообразие предсказаний в cloze-тесте: как выбор модели векторизации влияет на оценку сходства LLM с людьми

Проектное эссе¹

Вера Мони́на, БКЛ231

1. Введение

В курсовой работе этого года я проводила сравнение вероятностных распределений предсказаний GPT-4o-mini и Llama 3.1 с данными cloze-теста² на материале Русского корпуса предложений (Laurinavichyute et al., 2019; 144 контекста, 6 705 ответов). Сравнение на семантическом уровне было реализовано через статические эмбединги ruwikiruscorpora (word2vec, skipgram, 300 мер.): предсказания кодировались в виде пар лемма_UPOS, после чего вычислялись centroid similarity и NN Coverage. На защите мне задали вопрос: в какой мере выводы определяются выбором инструмента векторизации, и не изменится ли картина при использовании контекстуализированных эмбедингов?

Настоящее эссе систематически отвечает на этот вопрос. Мы сравниваем два типа эмбедингов³ (статические word2vec и контекстуализированные ruBERT) и три способа извлечения эмбединга из ruBERT.

2. Методология

2.1 Метрики

Исходная метрика NN Coverage @ θ фиксировала, какая доля вероятностной массы человеческих ответов покрывается хотя бы одним модельным предсказанием с косинусным сходством $\geq \theta$. На каждом уровне θ дополнительно вычислялись precision, Recall и F1 для того, чтобы развести полноту и точность модели. Также вычислялась метрика Centroid Similarity (CS) — косинусное сходство взвешенных центроидов двух распределений. Пороги $\theta \in \{0.70, 0.80, 0.90\}$; top-k⁵ $\in \{1, 5, 10, 20, 50, 100\}$.

2.2 Подходы к векторизации

Word2vec (ruwikiruscorpora). Статические эмбединги: один вектор на слово в формате лемма_UPOS. Плюсы: скорость, прозрачность. Минусы: нечувствительность к полисемии и изменениям семантики слов в различных контекстах.

ruBERT (DeepPavlov/rubert-base-cased). Контекстуализированные эмбединги; вектор токена формируется динамически с учётом полного контекста (в классических работах требуется двусторонний контекст, но в рамках cloze-теста у испытуемых есть только левый контекст). Реализованы три способа извлечения.

¹ https://github.com/VeraMonina/semantics_essay_2026

² в рамках cloze-теста испытуемым предъявляется незаконченный контекст, и им надо предсказать следующее слово. Пример: Надевая шапку цвета _____

³ в аннотации я указывала еще AdaGram, потому что видела этот тип эмбедингов в разной литературе, но у меня не получилось развернуть этот способ в коллабе.

⁴ в своей курсовой работе я брала такие параметры для ранжирования жесткости семант. близости, которое принималось валидным, чтобы можно было также оценить динамику сужения множества семантически близких кандидатов при ужесточении порога. Поскольку универсального значения θ , однозначно разделяющего близкие и неблизкие пары, не существует, анализ на серии порогов позволяет оценить устойчивость предсказаний и выбрать рабочий порог исходя из поведения кривых метрик, а не из абстрактной нормы.

⁵ top-k означает, что мы берем топ k слов отсортированных по убыванию вероятности.

2.3 Три способа извлечения эмбеддингов из ruBERT

- Способ А. Предсказанное слово подставляется на позицию пропуска; hidden state соответствующих субтокенов из последнего слоя берётся как вектор пары (контекст, слово). Это наиболее естественный аналог masked language modeling.
- Способ В. Вектор [CLS] левого контекста (без целевого слова) усредняется с вектором слова, поданного изолированно.
- Способ С. $\text{Residual} = v_A - v_{CLS(ctx)}$. Вычитание CLS-вектора контекста из способа А, то есть убирается «фоновый» контекстный сигнал, оставляя только вклад целевого слова.

3. Результаты

Таблица 1 содержит сводные результаты по всем метрикам при различных top_k и $\theta=0.70$ для обеих языковых моделей.

	GPT-4o-mini				Llama 3.1			
Подход	Centr.Sim	R@70	P@70	F1@70	Centr.Sim	R@70	P@70	F1@70
top_k	20				20			
word2vec	0.699	0.409	0.611	0.447	0.364	0.316	0.062	0.065
ruBERT-A	0.921	0.784	0.892	0.811	0.761	0.742	0.524	0.506
ruBERT-B	0.975	0.999	1.000	0.999	0.915	0.999	0.996	0.997
ruBERT-C	0.964	0.989	0.994	0.992	0.887	0.984	0.938	0.945
top_k	100				100			
word2vec	0.702	0.416	0.609	0.452	0.370	0.532	0.053	0.064
ruBERT-A	0.922	0.807	0.891	0.825	0.768	0.874	0.525	0.558
ruBERT-B	0.976	0.999	1.000	0.999	0.918	0.999	0.996	0.997
ruBERT-C	0.964	0.991	0.994	0.993	0.890	0.996	0.938	0.949

Таблица 1. Метрики при top-20 и top-100, $\theta=0.70$

Таблица 2 содержит сводные результаты по всем метрикам при различных top_k и $\theta=0.90$ для обеих языковых моделей. Также добавлена разница между F1 мерой при $\theta=0.70$ и $\theta=0.90$ для того, чтобы можно было увидеть влияние ужесточения параметра.

	GPT-4o-mini				Llama 3.1			
Подход	R@90	P@90	F1@90	$\Delta F1$ GPT	R@90	P@90	F1@90	$\Delta F1$ Llama
top_k	20				20			
word2vec	0.391	0.596	0.430	-0.017	0.291	0.050	0.057	-0.008
ruBERT-A	0.509	0.693	0.551	-0.260	0.394	0.196	0.170	-0.336
ruBERT-B	0.720	0.842	0.747	-0.252	0.648	0.313	0.317	-0.680
ruBERT-C	0.621	0.790	0.665	-0.327	0.542	0.335	0.303	-0.642
top_k	100				100			
word2vec	0.396	0.595	0.433	-0.019	0.489	0.041	0.054	-0.010

	GPT-4o-mini				Llama 3.1			
Подход	R@90	P@90	F1@90	$\Delta F1$ GPT	R@90	P@90	F1@90	$\Delta F1$ Llama
ruBERT-A	0.526	0.692	0.560	-0.264	0.605	0.193	0.203	-0.355
ruBERT-B	0.747	0.843	0.762	-0.237	0.839	0.313	0.363	-0.634
ruBERT-C	0.643	0.790	0.677	-0.316	0.732	0.335	0.351	-0.598

Таблица 2. Метрики при top-20 и top-100, $\theta=0.90$

3.1 Описание результатов word2vec

Результаты на статических эмбедингах показали значительные различия между двумя моделями. Для GPT-4o-mini значение косинусного сходства $CS = 0.70$ при $F1@70 = 0.45$ указывает на то, что модельные предсказания в основном располагаются в общем семантическом пространстве с человеческими ответами, но степень их близости остаётся ограниченной. При этом Precision (0.61) превышает Recall (0.42): предсказания GPT, то есть значительная часть человеческих ответов остаётся непокрытой (что важно было очень важно для моей курсовой работы).

Для Llama результаты указывают на меньшее перекрытие распределение предсказаний. При top_20 Recall = 0.316, Precision = 0.062, F1 = 0.065. При переходе к top_100 Recall резко вырастает до 0.532, тогда как Precision падает до 0.053, что ведет к тому, что F1 метрика почти не меняется (0.064). То есть модель генерирует широкое, семантически размытое распределение, которое не пересекается с человеческими ответами в статическом пространстве.

Особенно интересно, что увеличение порога до $\theta = 0.90$ не дает значимого ухудшения по метрикам. Это означает: найденные моделью семантические соответствия не являются случайными — они формируют устойчивое семантически близкое распределение к людям, которое сохраняется даже при ужесточении критерия схожести.

3.2 Описание результатов RuBERT способ А

Способ А отражает те же распределения предсказаний совсем по-другому. Для GPT-4o-mini $CS = 0.92$, $F1@70 = 0.811$ (top_20) и 0.825 (top_100) — рост при переходе к top-100 умеренный, что снова указывает на насыщение после первых 20 предсказаний. Precision (0.89) и Recall (0.78–0.81) сбалансированы: GPT точно и полно воспроизводит человеческое семантическое распределение.

Для Llama способ А даёт $F1@70 = 0.506$ при $k=20$ и 0.558 при $k=100$ (при этом опять с выраженной асимметрией: Recall = 0.874, Precision = 0.525). Llama хорошо охватывает человеческие ответы (высокий Recall), но её собственные предсказания во многом выходят за пределы человеческого распределения (низкая Precision). При $\theta = 0.90$ разрыв между моделями увеличивается: GPT результаты F1 при $k=100$ удерживаются на 0.560, а результаты Llama падают до 0.203.

3.3 Описание результатов RuBERT способ В

Значения метрик, полученных способом В, такие высокие, потому что левый контекст одинаков для людей и для модели, CLS-векторы контекста тождественны, и при усреднении они притягивают все векторы в одну точку пространства. Особенно это видно для $\theta = 0.70$, для $\theta = 0.90$ этот эффект частично исчезает и F1 Llama (top_20)

падает до 0.317, однако мы всё равно понимаем, что на данные результаты ориентироваться неправильно, так как данный метод оказался непригоден для сравнений множеств предсказаний, данных для одних и тех же контекстов.

3.4 Описание результатов RuBERT способ С

Способ С устраняет проблему способа В: для GPT-4o-mini $CS = 0.964$, $F1@70 = 0.992$ (top_20) и 0.993 (top_100) — значения почти идентичны, подтверждая насыщение. Precision и Recall симметричны (≈ 0.99). Для Llama способ С даёт метрика $F1@70 = 0.945$ (top_20) и 0.949 (top_100) — заметно выше способа А, — однако при $\theta=0.90$ асимметрия сохраняется: $Recall = 0.542$ vs 0.732 , $Precision = 0.335$, $F1 = 0.303$ vs 0.351 .

Также была подсчитана корреляция метрик F1 между способом С и другими подходами, чтобы определить насколько одинаково (но с разными абсолютными значениями) кодируется распределения ответов. Подсчитанная корреляция близка к нулю ($r \approx 0.05-0.12$), что, скорее всего, говорит о том, что способ С, в целом, по-другому кодирует семантическое пространство распределений.

3.5 Отдельное описание результатов по Centroid Similarity

Как и для анализа F1 метрики (а также Prec. и Rec.), по данной метрике наивысшие результаты выявляются при такой конфигурации: GPT + RuBert_C + top_100. Косинусное расстояние для ядра, полученного по предсказаниям Llama, систематически ниже. Однако, мне кажется важным заметить тот факт, что при переходе от статических эмбеддингов к контекстуальным косинусное расстояние для GPT увеличивается на ≈ 0.2 , а для Llama ≈ 0.4 . Я это интерпретирую так: предсказания GPT-4o mini, будучи семантически более точными и близкими к человеческим ответам, уже в пространстве Word2Vec располагались относительно кучно вблизи верных областей, поэтому дополнительная контекстуализация лишь уточняет их положение и прирост, соответственно, небольшой. Предсказания Llama, напротив, семантически более размытые и разнородные: Word2Vec не способен отразить их смысловую близость к ответам людей там, где она всё же существует и задаётся контекстом, тогда как RuBERT, чувствительный к контексту, частично эту близость восстанавливает.

4. Выводы

Мне кажется, наиболее важным результатом является то, что переход от рассмотрения top_20 к рассмотрению top_100 даёт минимальный прирост метрик для GPT-4o-mini ($\Delta F1@70 \leq 0.013$ по всем подходам) и умеренный для Llama в word2vec ($\Delta Recall = +0.22$ при $\Delta F1 \approx 0$). Это означает, что семантически распределения GPT концентрированы и сосредоточены на первых top_20 предсказаниях, а добавление большего числа предсказаний не даёт дополнительного перекрытия с распределением людей. У Llama в word2vec рост Recall при переходе к top_100 не даёт роста F1 из-за одновременного падения Precision, то есть дополнительные предсказания семантически далеки от людей и затрагивают другие значения. $F1@70$ Llama варьируется от 0.064 (word2vec, top_100) до 0.949 (ruBERT-C, top_100), что указывает на преимущество контекстуальных эмбеддингов. Также важно заметить, что Llama, в целом, охватывает нужную семантическую зону предсказаний людей, но с избыточной дисперсией, что выражается в высоком Recall при низкой Precision.

GPT-4o-mini превосходит Llama 3.1 при всех подходах, top-k и порогах. Это также было выявлено на других уровнях анализа, которые я проводила в рамках своей курсовой работы (поверхностном и синтаксических уровнях).


Способ С (ruBERT-residual) я буду использовать, если работа дойдет до публикации, потому что он устраняет артефакт способа В, даёт минимальную дисперсию по контекстам, семантически интерпретируем и одинаково информативен при top-20 и top-100. Способ А пригоден как проверочная метрика.

5. Избранная литература


Laurinavichyute, A. K., Sekerina, I. A., Alexeeva, S., et al. (2019). Russian Sentence Corpus: Benchmark measures of eye movements in reading in Russian. Behavior Research Methods, 51, 1161–1178.

Taylor, W. L. (1953). Cloze procedure: A new tool for measuring readability. Journalism Quarterly, 30, 415–433.

Приложение:



Значения метрики F1 при разных параметрах (можно также отследить изменение при $\theta = 0.80$, чего не было отражено в основном тексте).



Распределение Centroid Similarity по контекстам при top_20.

Мне кажется, что по данному графику хорошо видно, что у Llama больше контекстов, в которых центроиды семантически далеки от центроидов людей, что при усреднении дает тот результат, который был виден по таблицам.